

ДИСЦИПЛИНА	Математика в программировании (часть 2/2)
ИНСТИТУТ	Перспективных технологий и индустриального программирования
КАФЕДРА	Индустриального программирования
ВИД УЧЕБНОГО МАТЕРИАЛА	Материалы для практических/семинарских занятий
ПРЕПОДАВАТЕЛЬ	Холмогоров Владислав Владиславович
СЕМЕСТР	6, 2025-2026

Практическая работа № 3

«Генерация табличных данных»

по дисциплине «Математика в программировании (часть 2/2)»

Цели: приобрести навыки генеративных интеллектуальных алгоритмов для выполнения задачи генерации табличных данных.

Задачи:

1) С помощью моделей генерации табличных данных сгенерировать набор данных, на основе которого возможно провести обучение дискриминативных моделей для решения задач, описанных в Практической работе №1 и Практической работе №2:

- определить предметную область решаемой задачи (лучше всего выбрать задачу и набор данных, уже предобработанный в практических работах №1 и №2);

- в соответствии с задачей предметной области выбрать и обучить на предварительно обработанных данных (см. Практическая работа №1) генеративную модель табличных данных (см. **Примечание 1**);

- провести анализ распределения данных методами, аналогичными методам Практической работы №1 (изучить дисперсию данных, баланс классов, шумовые значения и статистические меры), при необходимости провести предварительную обработку сгенерированных данных.

В качестве дополнительного задания реализовать хотя бы один из следующих пунктов (один – на оценку 4, все – на оценку 5):

- выполнить пункты задания Практической работы №2 для сравнения результатов обучения дискриминативных моделей на естественных (выбранных вручную данных) и синтетических данных, рассчитать метрики качества и описать причины различия результатов (см. **Примечание 2**);

- выполнить не менее двух алгоритмов генерации табличных данных, один из которых должен основываться на экспертных моделях (см. **Примечание 3**), провести сравнительный анализ всех наборов данных.

ПРИМЕЧАНИЕ:

1) Для генерации табличных данных существуют как модели классического (неконнекционистские) машинного обучения – **Gaussian Mixture Model (GMM), Байесовские сети и Copula**, так и модели глубокого (нейронные) машинного обучения, основанные на генеративно-сопоставительных нейронных сетях (GAN), вариационных автокодировщиках (VAE) и диффузионных моделях (DF) – **TableGAN, CTGAN, TVAE, TabDDPM (Tabular Denoising Diffusion Probabilistic Models), TabSyn**. Если первые (классические) дают более усреднённые результаты в силу упрощённых моделей аппроксимирующих поверхностей, то нейронные модели позволяют куда более сложные связи между признаками для генерации более реалистичных синтетических данных, однако если классические методы чаще требуют для обучения только базовой предобработки данных (потому что любое исходное представление в случае применения таких моделей всё будет обобщено до простой модели, например, нормального распределения), то нейронные сети требуют более тщательной предварительной обработки, выбора алгоритма оптимизации весов (обучения модели), регуляризации для предотвращения переобучения, а также квантизации (уменьшения весов за счёт превращения больших дискретных значений в малые действительные) и иногда дистилляции (обучение упрощённой модели, имитирующую поведение данной), что является трудоёмким процессом. Существует также возможность генерации данных на основе экспертных правил, которые не требуют обучения и других дополнительных операций (кроме проверки системы аксиом на полноту и непротиворечивость в некоторых случаях), однако они требуют экспертных знаний, которые может извлечь из данных только эксперт в предметной области, либо попытаться найти их с помощью анализа ассоциативных правил, однако корректность и точность правил, найденных без экспертного мнения эмпирически или аналитически может быть значительно ниже чем те зависимости, которые обнаружат модели машинного обучения.

2) Метрики анализа качества обучения генеративных моделей можно разделить на субъективные и объективные. **Объективные метрики напрямую проверяют полезность данных** на исходных (проверенных или обучающих) данных – TSTR (Train on Synthetic, Test on Real), а также проверяют содержит или не содержит набор данных конкретных обязательных или запрещённых данных (подобно кластеризации с ограничениями). **Субъективные метрики имеют объективную оценку только с точки зрения математического сходства** (близость в многомерном пространстве признаков и статистические меры совместной встречи), но НЕ с точки зрения фактической пригодности или изначального смысла данных, к таковым относятся: семантическая согласованность по SHAP (SHapley Additive exPlanations, метод интерпретации моделей машинного обучения, основанный на теории игр, позволяющий количественно оценить вклад каждого признака в конечный прогноз модели), расстояние до ближайшей записи – DCR (DCRBaselineProtection, находит минимальное расстояние между синтетической и реальной строками данных для оценки их деперсонализации сгенерированных данных), сравнение данных по корреляциям и дисперсии признаков, графиков понижения размерности, средних, медиан, частот категорий, также существуют комбинированные метрики, которые позволяют одновременно оценить несколько статистических мер признаков, например, TabSynDex (общая оценка, комбинирующая статистическое сходство и сохранение корреляций).

3) Задача моделей и алгоритмов машинного обучения, как правило, сводится к снятию с человека когнитивной нагрузки процесса изучения свойств и закономерностей набора данных (для чего такие методы в принципе и были разработаны), однако экспертное мнение конкретного специалиста остаётся главным способом извлечения полезных паттернов. Однако, в случае отсутствия возможности привлечения эксперта подобные **экспертные правила** (конечно, не в таком же качестве) можно извлечь самостоятельно, **изучив предметную область набора данных**, его источники, способы и цели

сбора (задача Data collection – **Практическая работа №1**), а также проанализировав распределение, корреляции и другие статистические меры признаков, что требует достаточно больших временных затрат; более простым способом извлечения экспертных правил является анализ ассоциативных правил соответствующими методами (Apriori, Eclat, FP-growth), однако и для них необходимо определить анализируемые признаки и их границы (например, не имеет смысла анализировать отдельно взятые значения возраста – «31», «32», «33», ... и т.д., но имеет смысл анализировать их диапазон, например, «30-40» или «> 30», так как это даст большое количество экземпляров для таких правил, потому что **чем глубже и конкретнее правило, тем меньше объектов, удовлетворяющих его условию**), результатом любого из способов извлечения экспертных правил становится набор продукционных правил (логические правила вида « $A \rightarrow B$ »), формирующие базу правил (один из ключевых элементов базы знаний).

Качественно извлечённые экспертные продукционные правила позволяют генерировать логичные и типичные для конкретной задачи данные, они не всегда могут превзойти хорошо обученные искусственные нейронные сети, однако с небольшими усилиями превосходят классические генеративные модели. Также экспертные правила, даже если они и не будут применяться для генерации данных, могут быть применены для проверки корректности сгенерированных данных другими методами, а также для **обработки пропущенных, шумовых и других некорректных значений** исходного набора данных, поэтому поиск таких правил полезен в любом случае – отличительной способностью старших специалистов в области анализа и инженерии данных является быстрое и часто подсознательное извлечение подобных правил из исследуемого набора. **Рекомендуется для генерации данных реализовывать хотя бы одну модель из каждой группы:** модель классического машинного обучения, искусственную нейронную сеть и экспертную базу правил с последующим сравнительным анализом их результатов для выбора наиболее релевантного набора данных.